

# Biblioteca de Operadores Minería de Datos para Emergencias

Proyecto FONDEF ID 15 | 20560

Plataforma de Apoyo a la Gestión de Emergencia y Aplicaciones



UNIVERSIDAD  
DE SANTIAGO  
DE CHILE

## **Biblioteca de Operadores Minería de Datos para Emergencias**

Proyecto FONDEF ID 15 | 20560  
Plataforma de Apoyo a la Gestión de  
Emergencia y Aplicaciones

© Citiaps  
Derechos reservados.  
Primera edición: marzo 2021.

### **Contacto**

<https://citiaps.usach.cl>  
citiaps@usach.cl

# Tabla de contenidos

<b>Tabla de contenidos</b>	<b>3</b>
<b>Presentación   Resumen ejecutivo</b>	<b>4</b>
<b>Situación etapa 1</b>	<b>4</b>
Lista de clasificadores desarrollados en etapa 1	4
Actividades realizadas:	5
Metodología empleada:	7
<b>Situación etapa 2</b>	<b>7</b>
Actividades proyectadas:	8
Metodología de I+D	9
Estructura y Gramática de la Asertividad: Análisis de Twitter en contexto de Emergencias y Desastres.	9
Metodología: Análisis de Contenido Sintáctico	10
Procedimiento de Análisis.	10
<b>RESULTADOS</b>	<b>11</b>
<b>CONCLUSIONES</b>	<b>17</b>
<b>Referencias</b>	<b>17</b>

## Presentación | Resumen ejecutivo

En la etapa 2 esta biblioteca se declara como una iniciativa donde distintos grupos de investigación puedan aportar con nuevos clasificadores[1] , con diseño ajustado a la cultura y jerga chilena. Para esto es necesario definir una taxonomía que permita construir un directorio de operadores para facilitar a los desarrolladores de software encontrar e integrar operadores en sus aplicaciones. La biblioteca debe contener métodos supervisados y no-supervisados junto con documentación que describa el método y los resultados de pruebas y conjuntos de datos de experimentación (e.g., reportes técnicos o tesis). Si en esto se considera que prácticamente toda la gestión de emergencias se apoya en sistemas GIS, este esfuerzo también debería considerar la construcción de operadores espaciales y espacio-temporales que trabajan sobre capas de datos GIS.

El producto respectivo debe ser referenciado como el *Repositorio de Operadores de Inteligencia Computacional para Emergencias*.

## Situación etapa 1

Descripción del producto: Es un conjunto de objetos que contienen modelos de clasificación para texto construidos utilizando técnicas de inteligencia computacional y captura la información inicial de una etapa de crowdsourcing donde intervienen voluntarios humanos para etiquetar. Los operadores se hacen disponibles al público mediante una biblioteca con un API para objetos en lenguaje Java.

Hipótesis Operadores: Es posible crear clasificadores basados en métodos de aprendizaje supervisados y usar voluntarios para pre-etiquetado, para detectar clases relevantes en la construcción de aplicaciones para gestión emergencias y detección de necesidades de población afectada por desastres.

## Lista de clasificadores desarrollados en etapa 1

Afecto: Respuesta de un acontecimiento o hecho específico que lleva a cambios fisiológicos y endocrinos que tiene como finalidad la adaptación al ambiente. Se clasifican las respuestas en afectivas de tipo positivo, negativo, neutro o no aplica. Entre los positivos se encuentran palabras asociadas a entusiasmo, satisfacción, diversión, alivio etc. En el caso negativo cansancio, miedo pánico, etc.

**Sentimientos:** se evaluó un clasificador correspondiente a una emoción básica. El miedo, la cual es producida por la percepción de un peligro real. La cual se encuentra muy ligada al estímulo que la genera. Se clasifican las respuestas en miedo, ausencia de miedo y no es aplicable. En la expresión de miedo se califican expresiones que reflejan peligro o ataque, solicitud de ayuda o protección.

**Asertividad:** se refiere a la habilidad personal que permite expresar de forma sincera, abierta y oportuna pensamientos opiniones y emociones en el momento adecuado. Clasificado en Mensaje asertivo, no asertivo, no aplica. Entre los mensajes asertivos se pueden encontrar mensajes donde se expone información, opiniones y emociones de forma respetuosa y sincera que se relaciona con una emergencia y/o desastre de forma pertinente a la situación. En el caso de no ser asertiva la información, opiniones o emociones son dichas en forma agresiva o irrespetuosa, y son oportunas a las necesidades del momento. Para el caso de este clasificador se realizó un trabajo para delimitar la estructura gramatical y los componentes lingüísticos de la asertividad en twitter, el informe de este trabajo se detalla más adelante.

**Informatividad:** propuesto en [1] y se utiliza para identificar el tweet tiene información relacionada al desastre en cuestión, o no. Las clases aquí son las siguientes: Informativo y pertinente al desastre; Pertinente pero no informativo; No relacionado con el desastre o no aplicable. Se determina si tiene o no información útil que ayuda a la comprensión de la situación del desastre.

**Tipo de información:** esta categoría también se obtiene de [1]. Tiene como objetivo identificar de manera más precisa la información que tiene el tweet, a diferencia del anterior que contenía solo si la información aportaba información útil al desastre específico. Las diferentes clases en este caso son las siguientes: Gente afectada; Infraestructura de servicios públicos; donaciones y voluntariado; advertencia y consejos; simpatía y apoyo emocional; otra información útil o no aplica. Como ejemplo de gente afectada se tiene información de muertes lesiones, gente perdida, desplazada o encontrada.

## Actividades realizadas:

Las actividades realizadas se pueden resumir en cuatro grandes puntos: construcción del conjunto de datos; determinación de palabras claves; crowdsourcing y etiquetado en tiempo real; y uso de técnicas de aprendizaje supervisado.

- Para la construcción del conjunto de datos desde twitter se utilizaron dos fuentes de datos reales, a saber: 1. Terremoto Iquique del 1 de abril de 2014,

que afectó, Arica, Parinacota, Tarapacá y Antofagasta. 2. La inundación en Santiago el 17 de abril del año 2016. Varios sectores de la capital fueron afectados, siendo la comuna de Providencia una de las más afectadas. Todos los tweets son recolectados de [2]. Twitter facilita la propagación de información en tiempo real a una gran cantidad de usuarios. Esto hace que sea un ambiente ideal para la difusión de noticias directamente desde la fuente y/o ubicación geográfica de los acontecimientos [3]. De [4] se analizan los niveles de fidelidad de la información de esta red social los cuales fueron considerados.

- Palabras claves: El API pública de Twitter ofrece dos criterios para la recolección de tweets; basado en palabras clave (keywords) o en la geolocalización del usuario [5]. Palabras clave recolectan mayor cantidad de tweets de utilidad, pero estas varían mucho de un desastre a otro [6-7]. Para evitar este problema se recolectan y filtran tweets relevantes, los cuales con el transcurso del tiempo mejoran la clasificación.
- Crowdsourcing y etiquetado: El problema aquí es etiquetar los tweets recolectados, para luego pasar al entrenamiento supervisado de los clasificadores. Se utiliza una plataforma de crowdsourcing donde los voluntarios realizan el etiquetado [1]. La implementación se realiza usando herramientas de colaboración distribuida, en este marco la plataforma open source PyBossa [8]. Este tipo de etiquetado disminuye la complejidad en el proceso de categorización de tweets donde generalmente se utilizan herramientas de NLP (Natural Language Processing). Uno de los problemas relevantes de este etiquetado es la cantidad de voluntarios requeridos y el tiempo de etiquetado para la gran cantidad de tweets generados en un desastre, interesante analizar lo estudiado en [9] donde determinan que se requieren años para etiquetar todos los tweets generados en el huracán Sandy.
- Para implementar los clasificadores, primero se realizó una selección de características (problema NP duro). Para este caso, se utiliza una selección de características dadas por la literatura una heurística que selecciona los contenidos de los tweets, las características binarias más utilizadas en la literatura [1-2]: las características que se extraen del texto más utilizadas son: unigramas; bigramas, Part of Speech (POS), Part of Speech tag-bigramas, clases Verbnet para cada verbo que aparece en el tweet. Los tres clasificadores evaluados fueron: Árboles de decisión, Clasificador Bayesiano ingenuo multinomial y SVM (Support Vector Machine), los cuales son ampliamente usados en la literatura de clasificación de texto en desastres [1-2,9], la evaluación fue realizada usando una validación cruzada de 10-dobles. También se analizó

el problema de desbalance de clases, usando SVM de una vía (one class SVM), pero los resultados no resultaron ser significativamente diferentes a las SVM convencionales.

## Metodología empleada:

La metodología fue implementada siguiendo secuencialmente los pasos de las actividades antes mencionadas, esto es: recolección de datos, extracción de palabras claves, etiquetado y finalmente clasificación con su respectiva evaluación.

La implementación se realizó usando la arquitectura AIDR (Artificial Intelligence for Disaster Response) ver [13]. AIDR es una plataforma open source que se puede ejecutar como una aplicación web, o descargandola para crear una instancia propia. Se compone de tres componentes principales; colector, etiquetador, y entrenador.

Los ejemplos de entrenamiento requeridos por el sistema se obtienen llamando a la plataforma de crowdsourcing Pybossa.

Se selecciona un conjunto pequeño de tweets para que sean etiquetados por los voluntarios, luego se entrena el clasificador para que asigne de manera automática etiquetas a los tweets recolectados.

La salida de AIDR (tweets clasificados) pueden ser obtenidos a través de adaptadores de salida, que están expuestos como una API. Adicionalmente, para mostrar los tweets clasificados en tiempo real en un mapa o cualquier otro widget de visualización.

## Situación etapa 2

Los resultados de la Etapa 1, al usar una combinación de etiquetado humano (crowdsourcing) y posterior clasificación supervisada son exitosos, pues los resultados generados varían entre 93% de precisión para clasificadores como asertividad y valores entre 85% y 70% para el resto de los clasificadores. Pero la etapa de etiquetado representa una elevada demanda de tiempo, lo que puede perjudicar el funcionamiento en línea de las herramientas implementadas, sobre todo en etapas tempranas del desastre.

Para esta segunda etapa es de gran interés contar con un etiquetado-entrenamiento más rápido para la totalidad de los clasificadores y más preciso para algunos clasificadores específicos (Ej: tipo de información - gente afectada – 70,6%)

Hipótesis: El diseño de clasificadores para detectar clases relevantes en la construcción de aplicaciones de software, diseñadas para gestión de emergencias y asistencia a víctimas, será mejorada usando aprendizaje incremental y métodos semi-supervisados (incorporando algoritmos no-supervisados).

## Actividades proyectadas:

Obtención de datos para construir clasificadores en base a simulaciones realizadas con las entidades asociadas al proyecto (pilotaje de aplicaciones). En este caso no se usarán datos solo de la plataforma twitter, además se incorporarán otros tipos de mensajes como los generados en los grupos de Whatsapp o Telegram, usados para el caso de la aplicación Rimay.

Sobre un subconjunto reducido de mensajes previamente etiquetados se implementarán aprendizaje incremental como en [11-12]. Con los cuales es posible realizar un aprendizaje paralelo mientras se incorporan clasificaciones supervisadas al aprendizaje. De esta manera se aumenta el conjunto de entrenamiento, con la consecuente disminución del tiempo de etiquetado y mejora en la clasificación.

La segunda alternativa para la introducción de mejoras a la etapa 1, es el uso de lo que se denomina aprendizaje semi-supervisado, el cual incorpora aprendizaje no-supervisado a la clasificación. Esta alternativa ya ha sido usada en el campo del análisis de las redes sociales a la respuesta de desastres [13-14]. La composición de esta arquitectura se basa en un clasificador supervisado inicial (similar a los usados en etapa 1), un método no supervisado de agrupamiento y finalmente una fase de extracción que obtiene tokens y frases que aportan información específica que aumenta el conjunto de mensajes etiquetados.

La tercera alternativa es de integrar las dos anteriores, esto es realizar una modificación al entrenamiento de los clasificadores incrementales, incorporando etapas de agrupamiento para incrementar los conjuntos de entrenamiento, durante el aprendizaje. Esta etapa presenta, eso sí, desafíos técnicos mayores pues en estricto rigor es la creación de nuevos métodos de aprendizaje automático, y existen sólo unos pocos intentos en esta línea como en [15].



Finalmente se realizarán evaluaciones comparativas de los clasificadores realizados en la etapa 1 y esta nueva propuesta. Esta vez, la evaluación no se realizará solo en la dimensión de la precisión y exactitud en la clasificación, también es necesario incorporar índices que den cuenta de los tiempos de procesos involucrados en cada arquitectura.

## Metodología de I+D

- Primero se realizarán pruebas con aprendizaje incremental, usando incremental SVM [14] como primer método a probar, se usarán primero los conjuntos de datos de twitter de la etapa 1, se evaluará su precisión con la totalidad de los clasificadores ya implementados. A continuación se usarán datos de otras plataformas como Whatsapp y Telegram.
- Las segundas pruebas se realizarán usando la estrategia semi-supervisada usando agrupamientos y filtrado para extracción de frases que contengan información específica. De igual forma que la implementación de la primera alternativa se usará primero los datos de twitter y luego Whatsapp y Telegram.
- La implementación de la combinación de aprendizaje incremental y estrategias no supervisadas se partirá por algunas iniciativas de la literatura como la modificación del clasificador Bayesiano ingenuo implementado en forma iterativa usando el algoritmo de máxima expectativa, como propuesto por Herndon y Caragea [15].

La parte arquitectural se comenzará usando alternativas de la literatura como Tweedr [13], luego se usará las arquitecturas ad-hoc, que resulten de cada alternativa, especialmente la de la fusión incremental y no-supervisada.

## Estructura y Gramática de la Asertividad: Análisis de Twitter en contexto de Emergencias y Desastres.

El objetivo de esta etapa fue delimitar la estructura gramatical y componentes lingüísticos de la asertividad de twitter emitidos en situaciones de emergencia de alto impacto social (terremotos, inundaciones). El empleo análisis de Contenido gramatical en un conjunto de 1,354 twitter emitidos en Chile, apoyado por software NVivo 11 Pro. El procedimiento de análisis fue en dos etapas sucesivas: (a) análisis de la estructura gramatical; y (b) análisis de los componentes gramaticales de asertividad. Los resultados indican que (A) la ASERTIVIDAD es una estructura de cuatro componentes que comunican: (a) lugar; (b) evento; (c) fuente de la información, y (d) Juicio declarativo

del autor del twitter. No obstante, en el análisis de los datos se encuentra que puede haber ASERTIVIDAD si el twitter no informa su fuente de información; (B) La NO ASERTIVIDAD, contiene los componentes: Lugar, evento, más el Juicio que se caracteriza por: ser negativo, burla y uso de términos malsonantes. Es interesante notar que los twitter NO ASERTIVOS, pueden prescindir de indicar el lugar al cual refieren la noticia. Se entrega palabras asociadas la asertividad en twitter.

## Metodología: Análisis de Contenido Sintáctico

La base de datos de análisis fue de un total de 1,354 twitter. La base fue revisada y se eliminaron datos repetidos. La definición de ASERTIVIDAD y NO ASERTIVIDAD inicial, y que oriento el análisis posterior de la estructura gramatical de los Twitter fue:

### A) Mensaje Asertivo:

Mensaje donde se exponen información, opiniones y emociones de forma respetuosa y sincera (sin agresividad ni sumisión). El mensaje debe estar relacionado a una emergencia y/o desastre y debe ser pertinente a las necesidades del momento o situación que se vive.

### B) Mensaje No Asertivo:

Expresión de información, opiniones y emociones agresivas o dicho de forma irrespetuosa. Es un mensaje es referido a la emergencia y/o desastre pero no es oportuno a las necesidades del momento o la situación que se vive.”

Dicha definición ha sido aplicada en un primer grupo de twitters (482) y se encontró concordancia inter-observador kappa de 0.842, el cual es considerado Muy Bueno.

## Procedimiento de Análisis.

Luego de la depuración de los datos (eliminar twitter repetidos y reescribir), la definición de mensaje ASERTIVO / NO ASERTIVO fue aplicado al conjunto de datos y se obtuvo un total de 566 Twitter clasificados como ASERTIVOS, y 69 twitters NO ASERTIVOS. Estos fueron seleccionados para proseguir con el análisis.

Los tweets seleccionados fueron analizados en su estructura gramatical interna, para indagar los elementos comunes de la estructura gramatical que caracterizan y diferencian los twitters ASERTIVOS de los NO ASERTIVOS.

Posteriormente se delimitaron las palabras asociadas a los Twitter ASERTIVOS y NO ASERTIVOS, y además las palabras asociadas a los componentes gramaticales que hacen la diferencia entre los juicios ASERTIVOS y los juicios NO ASERTIVOS.

# RESULTADOS

## A. LA ESTRUCTURA DE LA ASERTIVIDAD

El análisis de los twitter permite reconocer una estructura gramatical compuesta de los siguientes elementos.

- (1) LUGAR, del evento negativo.
- (2) EVENTO NEGATIVO, donde explicita de que se trata el evento.
- (3) FUENTE, donde se explicita la fuente de información a cual apela el autor del twitter.
- (4) JUICIO DECLARATIVO, donde el autor del twitter pide, crítica, valora lo que sucede respecto al evento descrito.
- (5) BURLA / IRONIA: Texto que en el contexto del twitter vincula al EVENTO NEGATIVO con apreciación positiva o alegre, o con referirse a las consecuencias del evento negativo como una reivindicación de justicia,
- (6) JUICIO CRITICO: Declaraciones negativas o pesimistas del EVENTO NEGATIVO. El juicio se refiere a una situación específica explícitamente manifiesta.
- (7) PALABRAS MALSONANTES: Uso de garabatos para realizar la critica a personas o situaciones relacionadas con EVENTOS NEGATIVOS. El juicio crítico es genérico -no esta vinculado a situación específica, o ni siquiera es manifestada-, y está redactado en claro lenguaje malsonante

Los twitter ASERTIVOS se componen las categorías 1 a 4.

Tabla 1: Ejemplo de Twitter ASERTIVOS en 4 componentes.

LUGAR (¿Dónde sucede?)	EVENTO NEGATIVO (¿Cuál es el evento?)	JUICIO (¿Qué pide, necesita, critica, valora el autor?)	FUENTE (¿a cual fuente apela el autor?)
chile	terremoto	reestablecer	gobierno
iquique	temblor	no para de temblar	bio bio
chile	sismos	vigilancia de condiciones del mar ante eventos sismicos	Centro Monitoreo OceAnico INOCAR
iquique	terremoto	ayudar a los afectados en chile	cnn
Antofagasta a Valparaiso	terremoto	Se cancela la alerta de tsunami	Cruz Roja
iquique	terremoto	Pescadores artesanales de Iquique estiman millonarias perdida	ahoranoticias
la costa	ola de tsunami	primera ola de tsunami ya golpeo la costa	Armada de Chile
borde costero	alerta de tsunami	Gran parte del borde costero del pais ya se encuentra en zona de seguridad	FuerzaChile RT reddeemergenci a

El análisis de Palabras sugiere que la mención del LUGAR y del EVENTO NEGATIVO es inherente al mensaje. Pero no es suficiente para hacerlo ASERTIVO.

Operacionalmente LA ASERTIVIDAD ES:

ASERTIVIDAD es: LUGAR + EVENTO NEGATIVO + JUICIO (SENTENCIA QUE DECLARA, SOLICITA, CALIFICA, el evento) + FUENTE

No obstante, como lo sugieren los datos, el citar a la FUENTE agrega precisión a la ASERTIVIDAD del mensaje, pero no le resta ASERTIVIDAD si no está presente. Se

codificará solamente para explorar si citar la FUENTE de la información hace una distinción especial sobre la estructura del JUICIO.

Tabla 2: Ejemplo de Twiter NO ASERTIVOS analizados en sus componentes

LUGAR (¿Dónde sucede?)	EVENTO NEGATIVO (¿Cuál es el evento?)	BURLA / IRONIA	JUICIO CRITICO	PALABRAS MALSONANTES	FUENTE
chile	terremoto	Che chileno che chileno, que amargado se te ,cuando venga un tsunami que TE AYUDE UN INGLES			
chile	castigo		castigo para chile		
	terremoto			Bajo presion la mierda flota mas ligera	
chile	terremoto			Deberian requisarle todos los productos a los hueones que especulan los precios y mandarlos a la justicia por usurero	
	terremoto		Dejen de especular y preocupen se por la ayuda real mas q por		

seguir  
sembrand  
o la  
psicosis  
colectiva

chile terremoto

No sean culiao co

---

El análisis de Contenido de las Twitters NO ASERTIVOS, pone en evidencia otras variantes de la categoría JUICIO en los twitters:

BURLA / IRONIA: Texto que el contexto del twitter vincula EVENTO NEGATIVO con apreciación positiva o alegre, o con referirse a las consecuencias del evento negativo como una reivindicación de justicia,

Ejemplo:

- "...Che chileno che chileno ,que amargado se te ,cuando venga un tsunami que TE AYUDE UN INGLÉS<sup>TMa</sup>"
- "...Quieres que llore?"

JUICIO CRITICO: Declaraciones negativas o pesimistas del EVENTO NEGATIVO. El juicio refiere a una situación específica explícitamente manifiesta. Aquí dos ejemplos referidos el primero a la especulación, y el siguiente a la perdida de niños tras el terremoto:

- "...Deberian requisarle todos los productos a los hueones que especulan los precios.."
- "...Yo cacho que se pierden niños por culpa de las viejas culias histericas!"

PALABRAS MALSONANTES: Uso de garabatos para realizar la critica a personas o situaciones relacionadas con EVENTOS NEGATIVOS. El juicio crítico es genérico -no esta vinculado a situación específica, o ni siquiera es manifestada-, y esta redactado en claro lenguaje malsonante.

- "...dos dias durmiendo como la mierda y mas asusta que la rechuha.."
- "...Da la Cara vieja de Mierda..."

El análisis comparativo de juicios ASERTIVOS y NO ASERTIVOS sugiere que la diferencia sustancial entre uno y otro es la calidad de los juicios. La ASERTIVIDAD es la confluencia de PROPOSICIONES O FRASES que refieren a: (1) EVENTO NEGATIVO + (2) LUGAR, + (3) JUICIO, y, eventualmente, + (4) FUENTE de la noticia.

ASERTIVIDAD = LUGAR + EVENTO NEGATIVO (+ FUENTE) + JUICIO (declaración).

NO ASERTIVIDAD = LUGAR + EVENTO NEGATIVO (+ FUENTE) + JUICIO (Burla, juicio critico, palabras malsonantes).

Los twitters ASERTIVOS tienen juicios de ALERTA y POSIBILIDAD. Son juicios positivos o negativos que plantean ALERTA (necesidades, críticas, valoraciones); y POSIBILIDAD (lo que se espera, lo que se cree, lo que se proyecta). En tanto los TWEETERS NO ASERTIVOS, tienen categorías como: (1) BURLA e IRONIA; (3) JUICIO MAL SONANTES; y (4) JUICIOS CRITICOS.

#### B PALABRAS ASOCIADAS A LA ASERTIVIDAD.

El análisis de la estructura de los twiter ASERTIVOS y NO ASERTIVOS ponen en evidencia que estos comparten algunos componentes como: (a) referencial al LUGAR, y (b) referencia al evento negativo. La diferencia entre unos twiter y otros es la construcción gramatical del juicio, que en los Twitters ASERTIVOS se ha definido como “juicios Declarativos”, y en los twitters NO ASERTIVOS por juicios definidos como Burla/ironia, juicio con palabras malsonantes y juicios críticos negativos.

Lo que se realizó a continuación es delimitar las palabras asociadas a la ASERTIVIDAD respecto precisamente a la estructura de los juicios con las cuales aquí se las ha caracterizado (Tabla 3).

Tabla 3. Listado de las 20 primeras palabras más frecuentes asociadas a ASERTIVIDAD y las 20 primeras palabras asociadas a NO ASERTIVIDAD.

PALABRAS ASOCIADAS ASERTIVAS				PALABRAS ASOCIADAS A NO ASERTIVIDAD			
Palabra	Conte o	Porcentaj e ponderad o (%)	Palabras similares	Palabra	Conte o	Porcentaj e ponderad o (%)	Palabras similare s
municip al	39	002	antofagast a, lima, municipal, para, quito, rio, santiago, sur, tirana, valparaiso	que	29	005	que
tsunami	37	002	tsunami	los	10	002	los

del	31	002	del	por	10	002	por
agua	29	002	agua, aguas	chile	8	001	chile
por	28	002	por	con	7	001	con
que	28	002	que	las	7	001	las
los	26	002	los	mierda	7	001	mierda
alerta	24	001	alerta	agua	5	001	agua
personal	25	001	alcalde, alonso, carter, con, cortes, don, haber, maestro, paul, personal, post, responder, son	para	5	001	para
chile	17	001	chile	tsunam i	5	001	tsunami
las	15	001	las	mas	5	001	mas
terremot o	15	001	terremoto	sin	4	001	sin
iquique	13	001	iquique	como	4	001	como
parte	18	001	costa, dice, interior, parte, region, regiones, saber, zona	lluvia	4	001	lluvia
sin	10	001	sin	pero	4	001	pero
norte	10	001	norte	hay	3	001	hay
alarma	8	000	alarma, alarmas	imbecil	3	001	imbecil, imbecile s



mapoch o	8	000	mapocho	chileno	3	001	chileno, chilenos
arica	7	000	arica	eso	3	001	eso

## CONCLUSIONES

Se ha definido la estructura de la ASERTIVIDAD.

Se ha definido la diferencia entre la ASERTIVIDAD y la NO ASERTIVIDAD en los twitter

Se ha determinado palabras ASOCIADAS A LA ASERTIVIDAD.

## Referencias

[1] Muhammad Imran, Shady Elbassuoni, Carlos Castillo, Fernando Diaz, and Patrick Meier. Extracting information nuggets from disaster- related messages in social media. In Proceedings of the 10<sup>th</sup> International ISCRAM Conference, Baden-Baden, Germany, May 13-17, 2013, pages 26-33, 2013.

[2] Muhammad Imran, Prasenjit Mitra, and Carlos Castillo. Twitter as a lifeline: Human-annotated twitter corpora for nlp of crisis-related messages. In Proceedings of the Tenth International Conference on Language Resources and Evaluation (LREC 2016), Paris, France, may 2016. European Language Resources Association (ELRA).

[3] Carlos Castillo, Marcelo Mendoza, and Barbara Poblete. Information credibility on twitter. In WWW '11 Proceedings of the 20th international conference on World wide web, New York, USA, October 25-29, 2011, pages 675-684, 2011.

[4] Marcelo Mendoza, Barbara Poblete, and Carlos Castillo. Twitter under crisis: can we trust what we rt? In SOMA '10 Proceedings of the First Workshop on Social Media Analytics, Washington, USA, July 25-29, 2010, pages 71-79, 2010.

[5] <https://dev.twitter.com/streaming/public>.

[6] Alexandra Olteanu, Carlos Castillo, Fernando Diaz, and Sarah Vieweg. Crisislex: A lexicon for

collecting and filtering microblogged communications in crises. In Proceedings of the Eighth International AAAI Conference on Weblogs and Social Media, California, USA, June 1-4, 2014, pages 376-385, 2014.

[7] Sarah E. Vieweg. Situational Awareness in Mass Emergency: A Behavioral and Linguistic Analysis of Microblogged Communications. SelectedWorks, Qatar Computing Research Institute, 2012.

[7] <http://pybossa.com/>

[8] Ferda OI, Patrick Meier, Muhammad Imran, Carlos Castillo, Devis Tuia, Nicolas Rey, and Julien Briant. Combining human computing and machine learning to make sense of big (aerial) data for disaster response. Big Data, 4(1):47-59, 2016.

[9] Sungil Kim, Heeyoung Kim, and Younghwan Namkoong. Ordinal classification of imbalanced data with application in emergency and disaster information services. IEEE Intelligent Systems, PP(99):1-18, 2016.

[10] Muhammad Imran, Carlos Castillo, Ji Lucas, Patrick Meier, and Sarah Vieweg. AIDR: Artificial intelligence for disaster response. In 23rd International Conference on World Wide Web (2014), Seoul, Korea, April 7-11, 2014, page 159-162, 2014.

[11] Xinghua Fan, Shaozhu Wang, et al. An incremental learning algorithm considering texts' reliability, International Journal of Advanced Computer Science and Applications (IJACSA), Vol. 3, No. 2, 2012 23.

[12] Cao Jianfang and Wang Hongbin, An improved incremental learning algorithm for text categorization using support vector machine, Journal of Chemical and Pharmaceutical Research, 2014, 6(6):210-217.

[13] Ashktorab Z., Brown C., Nandy M. and Culetta A. TWEEDR: Mining twitter to inform disaster response, In: Proceeding of the 11<sup>th</sup> ISCRAM conference 2014.

[14] Li H. et al, Twitter mining for disaster response: a Domain adaptation approach. In: Proceeding of the ISCRAM conference 2015, 57-57.

[15] Herdon N. and Caragea D. Empirical study of domain adaptation with Naïve Bayes on the task of splice site prediction. In: Proceeding of the bioinformatics 2014, 57-57.

## Operadores utilizados en Aysana

### Monitor de redes sociales (peak\_detector)

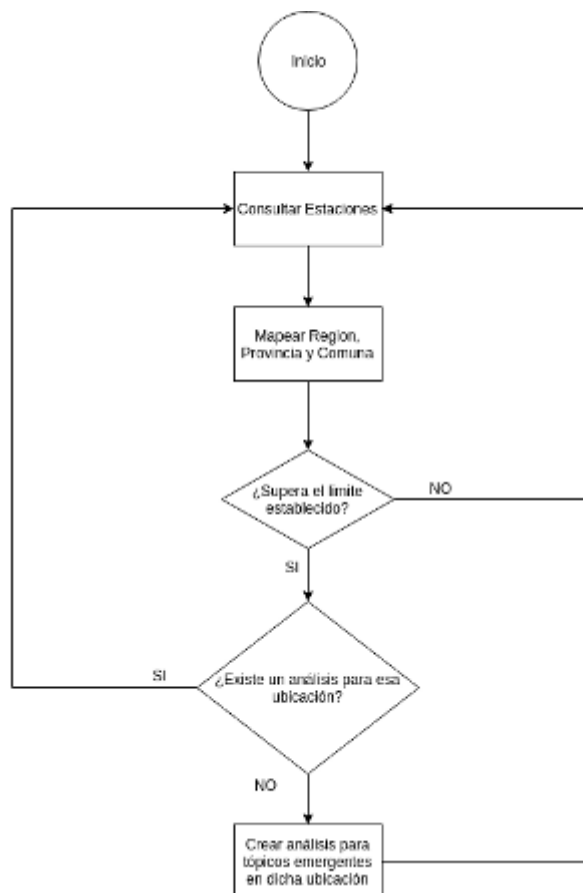
Este servicio está a la escucha constante de ciertas palabras clave en redes sociales (Twitter), estas palabras clave permiten detectar si se habla sobre ciertos desastres de origen natural, en el caso de onemi les interesa detectar 7 desastres de origen natural: terremotos, maremotos, erupciones volcánicas, aluviones, incendios, inundaciones y tornados. Este servicio se enfoca en la frecuencia del uso de estas palabras clave, si hay un aumento abrupto en el uso de algunas de estas palabras clave, se dice que se ha detectado un evento, y se comienza a realizar un análisis automático. En esta entrega se ha optimizado el uso de recursos por parte de este servicio, así como permitir lanzar y detener manualmente eventos en caso de que el sistema falle en detectar alguno de estos eventos. Además el sistema guarda cada cierto periodo de tiempo el estado actual del servicio, permitiendo casos de uso que no eran posibles en la entrega anterior: recuperación del servicio en caso de una baja, edición de palabras clave.

### Detección de precipitaciones

El proyecto Vismet cuenta con una api que entrega el historial de precipitación para más de 500 estaciones en todas las regiones del país, con esta información se puede determinar el lugar en el que podrían ocurrir aluviones, remociones en masa, inundaciones u otros de los peligros asociados.

Lo que se realiza entonces en este nuevo componente es consultar periódicamente por los valores de precipitación de cada una de las estaciones, luego se identifica la ubicación completa (región, provincia, comuna), basándose en las coordenadas espaciales proporcionadas por la api, en caso de que se supere el valor establecido se consulta si ya existe un análisis para esa ubicación, en caso de pasar todas estas verificaciones se crea y lanza un análisis para tópicos emergentes que va a detectar los tópicos de acuerdo a lo que se esté hablando en el momento. Esto se realiza con el fin de obtener registros de lo que está sucediendo en el lugar afectado y que el organismo

técnico pueda tomar una decisión informada. El diagrama de flujo de este proceso se describe a continuación.



Los límites de las precipitaciones acumuladas fueron establecidos por expertos de Sernageomin, basándose en eventos pasados. En la siguiente tabla se muestran estos límites en detalle.

Zona	Regiones	Umbral precipitaciones	
		Por hora	Acumulado (24 horas)
Arica y Parinacota - Coquimbo	Arica Y Parinacota	10 mm	30 mm
	Tarapacá	10 mm	30 mm
	Antofagasta	10 mm	30 mm
	Atacama	10 mm	30 mm
	Coquimbo	10 mm	30 mm
Valparaíso - Libertador General Bernardo O'Higgins	Valparaíso	10 mm	30 mm
	Isla De Pascua	10 mm	30 mm

	Metropolitana De Santiago	10 mm	30 mm
	Libertador General Bernardo O'higgins	10 mm	30 mm
Maule - Biobío	Maule	20 mm	70 mm
	Ñuble	20 mm	70 mm
	Biobío	20 mm	70 mm
Araucanía - Magallanes	Araucanía	20 mm	80 mm
	Los Ríos	20 mm	80 mm
	Los Lagos	20 mm	80 mm
	Aysén Del General Carlos Ibáñez Del Campo	20 mm	80 mm
	Magallanes Y De La Antártica Chilena	20 mm	80 mm

## Detección de tópicos emergentes

Realiza análisis sobre el texto de los tweets permitiendo descubrir tópicos populares dentro de la última ventana de tiempo. La actualización ocurre cada 12 minutos pero el análisis contempla datos de la última hora desde que ocurrió el evento; de esta manera los tópicos son más consistentes entre una actualización y otra, destacando aquellos tópicos que se mantienen populares durante el evento.

Los operadores de clasificación de texto para emergencia son un conjunto de objetos que contienen modelos de clasificación para texto construidos utilizando técnicas de inteligencia computacional y captura la información inicial de una etapa de crowdsourcing donde intervienen voluntarios humanos para etiquetar. Los operadores se hacen disponibles al público mediante una biblioteca con un API para objetos en lenguaje Java, por otro lado para la utilización dentro de la aplicación Aysana se desarrolló una adaptación de los operadores en lenguaje Python, esto permitió una mejor adaptación a la arquitectura de la aplicación y agregar nuevos tipos de operadores como es el caso de los tópicos emergentes. La lista de operadores desarrollados hasta el momento está mencionada en la tabla de la aplicación Aysana.

Existen dos etapas de validación, la primera consiste en utilizar conjuntos de datos de tweets de emergencias reales: 1. Terremoto Iquique del 1 de abril de 2014, que afectó, Arica, Parinacota, Tarapacá y Antofagasta. 2. La inundación en Santiago el 17 de abril del año 2016. Luego se realizó una extracción de palabras claves, seguido del proceso de etiquetado y finalmente clasificación con su respectiva evaluación.

Los resultados de la Etapa 1, al usar una combinación de etiquetado humano (crowdsourcing) y posterior clasificación supervisada son exitosos, pues los resultados generados varían entre 93% de precisión para clasificadores como asertividad y valores entre 85% y 70% para el resto de los clasificadores. Pero la etapa de etiquetado representa una elevada demanda de tiempo, lo que puede perjudicar el funcionamiento en línea de las herramientas implementadas, sobre todo en etapas tempranas del desastre.

Debido a esto en la segunda etapa primero se realizarán pruebas con aprendizaje incremental, usando incremental SVM como primer método a probar, se usarán primero los conjuntos de datos de twitter de la etapa 1, se evaluará su precisión con la totalidad de los clasificadores ya implementados. Las segundas pruebas se realizarán usando la estrategia semi-supervisada usando agrupamientos y filtrado para extracción de frases que contengan información específica.

Por otro lado se plantea el uso de un algoritmo de tópicos emergentes para dejar de lado el problema del etiquetado, la validación respecto a este tipo de algoritmos está siendo realizada mediante la aplicación Aysana.

Existen dos componentes de I+D, (i) la creación de una metodología para crear nuevos operadores de clasificación de texto para emergencia; y (ii) los operadores de clasificación de texto y cómo se van adaptando a las nuevas emergencias que se crean dentro de las aplicaciones.

En relación a (i), se establecen los pasos de las actividades antes mencionadas, esto es: recolección de datos, extracción de palabras claves, etiquetado y finalmente clasificación con su respectiva evaluación.

Para (ii), es necesario realizar pruebas y validación de acuerdo a lo descrito anteriormente. Se establecen diferentes conjuntos de datos donde se probaran y comparan en base a métricas los nuevos operadores de clasificación de texto.